

**T.C.
MERSİN ÜNİVERSİTESİ ERDEMLİ UYGULAMALI TEKNOLOJİ VE
İŞLETMECİLİK YÜKSEKOKULU YÖNETİM BİLİŞİM SİSTEMLERİ
ANABİLİM DALI**



BÜYÜK VERİ ANALİZİ FİNAL ÖDEVİ

Kalp Sağlığı Risk Faktörlerinin Analizi Ve Makine Öğrenmesi İle Tahminlenmesi

Hazırlayan

Zeynep NOM

22430040002

Danışman

Dr. Öğr. Üyesi Hüseyin YANIK

HAZİRAN, 2026, MERSİN

1. Giriş

1.1. Küresel Ölçekte Kardiyovasküler Hastalıkların Epidemiyolojisi ve Sosyo-Ekonomik Yüğü

Kardiyovasküler hastalıklar (KVH); koroner arter hastalıkları, serebrovasküler rahatsızlıklar, romatizmal kalp hastalıkları ve tromboemboli gibi kalbi ve damar ağını doğrudan etkileyen geniş bir patoloji yelpazesini kapsamaktadır. Günümüzde modern tıp bilimindeki devrim niteliğindeki gelişmelere, farmakolojik tedavi alternatiflerinin çeşitlenmesine ve cerrahi müdahale tekniklerindeki yüksek başarı oranlarına rağmen, KVH küresel ölçekte halk sağlığını tehdit eden en baskın kronik sağlık sorunu olma özelliğini korumaktadır. Dünya Sağlık Örgütü (WHO) verilerine göre, her yıl yaklaşık 17.9 milyon insan kardiyovasküler komplikasyonlar sebebiyle hayatını kaybetmektedir; bu sayı, küresel düzeydeki tüm ölüm nedenlerinin yaklaşık %32'sine tekabül etmektedir.

Kardiyovasküler hastalıkların oluşturduğu bu devasa yük, yalnızca bireysel sağlık kayıpları ile sınırlı kalmayıp, makroekonomik düzeyde iş gücü kaybına, erken emeklilik dalgalarına ve hastanelerin yoğun bakım ünitelerinde kronik yığılmalara neden olarak ulusal sağlık bütçeleri üzerinde sürdürülemez bir finansal baskı yaratmaktadır. Hastalığın patogenezi incelendiğinde; genetik yatkınlıklar ve kronik hücresel yaşlanma gibi değiştirilemez unsurların yanı sıra, tütün kullanımı, sedanter yaşam tarzı, dengesiz beslenme, obezite ve kontrolsüz stres gibi tamamen modifiye edilebilir (değiştirilebilir) mikrodavranışsal alışkanlıkların birincil tetikleyici olduğu görülmektedir. Bu çok boyutlu yapı, hastalığın takibini ve yönetimini karmaşık bir epidemiyolojik problem haline getirmektedir.

1.2. Reaktif Tıptan Proaktif ve Önleyici Tıba Geçiş Paradigması

Geleneksel tıp paradigmaları, tarihsel süreç boyunca ağırlıklı olarak "reaktif" bir felsefe üzerine inşa edilmiştir. Bu yaklaşımda birey, ancak semptomlar klinik olarak belirgin hale geldiğinde, organ hasarı başladığında veya akut bir kriz (akut miyokard enfarktüsü vb.) anında sağlık sistemine başvurmaktadır. Reaktif müdahaleler hayat kurtarıcı olsa da, damar endotel yapısında meydana gelen geri döndürülemez deformasyonları tamamen ortadan kaldıramamakta ve hastayı ömür boyu farmakolojik tedaviye bağımlı kılmaktadır. 21. yüzyılın modern sağlık yönetimi vizyonu ise bu statükoyu kırarak, odağı hastalıktan ziyade "sağlıklılık halinin korunmasına" kaydıran, yani semptomlar henüz ortaya çıkmadan risk gruplarını belirlemeyi amaçlayan "proaktif, önleyici ve kişiselleştirilmiş tıp" stratejilerine odaklanmaktadır.

Önleyici tıbbın temel taşı, popülasyon içindeki bireylerin risk skorlamalarının doğru, dinamik ve süratli bir şekilde yapılabilmesidir. Geleneksel risk skorlama araçları (Framingham Risk Skoru gibi) genellikle sınırlı sayıda statik parametreye dayanmakta ve bireyin günlük yaşam tarzı dinamiklerini, psikososyal

stres yükünü veya anlık klinik dalgalanmalarını tam anlamıyla analiz sürecine dahil edememektedir. Bu noktada, bireylerin çok boyutlu sağlık verilerinin sürekli olarak izlenmesi, kaydedilmesi ve analitik süzgeçlerden geçirilmesi, proaktif tıp vizyonunun pratik hayata entegre edilebilmesi için yegane çözüm yolu olarak öne çıkmaktadır.

1.3. Sağlıkta Büyük Veri Analitiği ve Makine Öğrenmesinin Rolü

Sağlık bilişimi, giyilebilir teknolojik cihazlar, elektronik sağlık kayıtları (EHR) ve geniş kapsamlı hasta anketleri, tıp dünyasında "Büyük Veri" (Big Data) çağını başlatmıştır. Sağlık alanındaki büyük veri; hacim (volume), hız (velocity) ve çeşitlilik (variety) bileşenleri açısından insan beyninin veya geleneksel istatistiksel yazılımların manuel olarak korelasyon kuramayacağı kadar kompleks bir yapıya sahiptir. Bireyin kilosu, kan basıncı seviyesi, sigara kullanım sıklığı, uyku düzeni ve depresyon eğilimi gibi parametrelerin her biri, kardiyovasküler sistem üzerinde tekil etkiler yaratırken, bu özneliliklerin bir araya gelerek oluşturduğu sinerjik (birlikte) etkiler ölümcül olabilmektedir.

Bu karmaşık, doğrusal olmayan (non-linear) ve çok değişkenli ilişkilerin çözülmesinde Makine Öğrenmesi (Machine Learning) algoritmaları devreye girmektedir. Yapay öğrenme yaklaşımları, ham sağlık verilerindeki gizli kalıpları (patterns) keşfetme, değişkenlerin ağırlık derecelerini belirleme ve geleceğe yönelik yüksek doğruluklu tahminler üretme yeteneğine sahiptir. Sağlık sistemlerine entegre edilecek tahmine dayalı yapay zeka modelleri, hekimlerin klinik karar destek sistemlerini (CDSS) besleyerek, yüksek riskli hastaların erken evrede tespit edilmesini, kişiselleştirilmiş check-up programlarının oluşturulmasını ve böylece klinik kaynakların en optimum şekilde dağıtılmasını sağlamaktadır.

1.4. Çalışmanın Amacı ve Yapısal Kapsamı

Bu çalışmanın temel amacı, literatürde kapsamlı bir halk sağlığı taramasını temsil eden Heart_Disease_Risk Factors and Patient Health Survey Dataset (Heart_Dataset_Cleaned.csv) veri tabanı üzerinde uçtan uca bir veri bilimi hattı (pipeline) işletmektir. Proje, teorik veri bilimi metodolojileri ile pratik klinik bulguları köprülemeyi hedefleyen yedi ana operasyonel aşamadan oluşmaktadır:

- Keşifsel Veri Analizi (EDA): Veri setinin yapısal boyutları, değişken türleri, eksik veri ve mükerrer kayıt durumları taranarak veri bütünlüğü doğrulanacaktır.
- Tanımlayıcı İstatistiklerin Üretilmesi: Popülasyonun genel fizyolojik durumunu ve merkezi eğilimlerini yansıtacak ortalama, medyan, standart sapma ve frekans tabloları oluşturulacaktır.

- Görselleştirme Protokolü: Değişkenlerin dağılımları ve hedef değişken olan Heart patient ile olan ilişkileri, akademik standartlara uygun, eksen isimleri netleştirilmiş grafikler üzerinden görselleştirilecektir.
- Risk Faktörü Analizi: Tıp literatüründe kabul görmüş birincil patojenik etkenlerin (hipertansiyon, obezite, tütün kullanımı vb.) kalp hastalığı üzerindeki yüzdesel ve istatistiksel ağırlıkları çapraz tablolarla sorgulanacaktır.
- Makine Öğrenmesi Modellemesi: Veri seti %80 eğitim ve %20 test olarak ayrıştırılacak, kategorik öznitelikler sayısallaştırılacak ve Heart patient durumunu öngörebilmek amacıyla en az iki farklı sınıflandırma algoritması eğitilecektir.
- Performans Karşılaştırması: Modeller; doğruluk (Accuracy), kesinlik (Precision), duyarlılık (Recall) ve F1-skor metrikleri ile karmaşıklık matrisleri (Confusion Matrix) üzerinden değerlendirilecektir.
- Klinik ve Kritik Yorumlama: Elde edilen analitik sonuçların tıp dünyasındaki karşılığı, modelin değişken önem dereceleri, veri setinin örneklem boyutu ve hastaların öz-beyanına (self-reported) dayalı kısıtları bilimsel bir dille tartışılarak sonuçlandırılacaktır.

2. Veri Setinin Tanıtımı

Bu araştırmada analitik modellemeye tabi tutulan veri seti, literatürde "Heart Disease Risk Factors and Patient Health Survey Dataset" başlığı altında yer alan ve proje dosyasında Heart_Dataset_Cleaned.csv olarak adlandırılan ham veritabanıdır. Söz konusu veri seti, epidemiyolojik ve klinik takipleri kolaylaştırmak amacıyla yaklaşık 328 bireye ait sağlık, demografi ve mikrodavranışsal yaşam tarzı kayıtlarını içermektedir.

Veri setinin yapısı, insan sağlığını etkileyen faktörlerin çeşitliliğini yansıtacak biçimde dört ana katmanda sınıflandırılmıştır:

2.1. Demografik Değişkenler

Bireylerin temel kimlikssel ve sosyo-çevresel arka planlarını anlamak adına şu öznitelikler incelenmiştir:

- Age (Yaş): Kardiyovasküler yaşlanma ve damar elastikiyeti kaybı açısından en temel bağımsız değişkenlerden biridir.
- Gender (Cinsiyet): Hormonal yapının (örneğin östrojenin koruyucu etkisi) ve cinsiyete bağlı yaşam tarzı farklılıklarının analizi için kritik öneme sahiptir.
- Marital Status (Medeni Durum) & Living Situation (Yaşam Durumu): Bireyin sosyal destek mekanizmalarını ve bunun dolaylı olarak psikososyal sağlık üzerindeki etkilerini yansıtır.

2.2. Yaşam Tarzı ve Davranışsal Değişkenler

Kronik hastalıkların epidemiyolojisinde değiştirilebilir risk faktörlerini temsil eden parametrelerdir:

- Occupation / Daily Activities (Meslek / Günlük Aktiviteler): Sedanter (hareketsiz) yaşam standardının belirlenmesinde rol oynar.
- Food Habits (Beslenme Alışkanlıkları): Sodyum, doymuş yağ ve lif tüketim dengesinin dolaylı bir göstergesidir.
- Physical Activity (Fiziksel Aktivite) & Sleep at Night (Gece Uykusu): Metabolik hızı, kardiyorespiratör kondisyonu ve vücudun sirkadiyen ritmini düzenleyen unsurlardır.
- Depression (Depresyon) & Feel Stressed (Stres Hissi): Kronik kortizol salınımı ve sempatik sinir sistemi aktivasyonu yoluyla kalbe binen yükü ölçer.
- Smoke or Tobacco (Sigara/Tütün Kullanımı) & Alcohol (Alkol Tüketimi): Endotel fonksiyon bozukluğuna ve toksik vasküler etkilere yol açan birincil alışkanlıklardır.

2.3. Klinik ve Fiziksel Değişkenler

Bireylerin doğrudan fizyolojik durumunu ve tıbbi geçmişini gösteren objektif metriklerdir:

- Heart Problems & Diabetes History (Kalp ve Diyabet Geçmişi): Ailesel veya geçmişe dönük kronik zemin yükünü gösterir.
- Height (Boy), Weight (Kilo) & BMI (Vücut Kitle İndeksi): Obezite ve metabolik sendrom riskinin saptanmasında uluslararası altın standart bileşenlerdir.
- Blood Pressure (Kan Basıncı): Kalbin damarlara uyguladığı hidrolik basıncı ve hipertansiyon varlığını kategorize eder.
- Diabetes (Diyabet) & Medicines (Kullanılan İlaçlar): Mevcut glikoz metabolizması bozukluklarını ve hastanın farmakolojik tedavi bağımlılığını belgeler.

2.4. Hedef Değişken (Target Variable)

- Heart Patient (Kalp Hastası mı?): Analizin odak noktasını oluşturan, bireyin doğrulanmış bir kalp hastalığı tanısına sahip olup olmadığını belirten iki sınıflı (Kategorik: Yes / No) hedef değişkendir. Tüm makine öğrenmesi modelleri bu değişkeni yüksek doğruluk ve duyarlılıkla tahmin etmek üzere eğitilecektir.

3. Veri Ön İşleme

Veri analizi ve tahmine dayalı modelleme süreçlerinin başarısı; doğrudan ham verinin kalitesine, tutarlılığına ve doğruluğuna bağlıdır. Sağlık taramaları ve anket çalışmaları neticesinde elde edilen ham veriler; veri giriş hataları, eksik beyanlar, gürültülü (noisy) kayıtlar veya mükerrer veriler barındırmaya oldukça müsaittir. Bu tür yapısal bozukluklar temizlenmeden algoritmaların eğitilmesi, modellerde "çöp girerse çöp çıkar" (*garbage in, garbage out*) mekanizmasının çalışmasına ve klinik olarak kabul edilemez, yanlı (biased) sonuçların üretilmesine yol açar.

Bu çalışma kapsamında, analitik süreçlerin ve makine öğrenmesi modellerinin güvenilirliğini en üst düzeye çıkarmak amacıyla Heart_Dataset_Cleaned.csv veri seti üzerinde uçtan uca, sistemli bir veri ön işleme (*data preprocessing*) protokolü yürütülmüştür.

3.1. Veri Setinin Yapısal Boyutları ve Öznitelik Tanımlamaları

Python ortamında veri setinin genel matris boyutlarını ve sütun isimlerini belirlemek adına `df.shape` ve `list(df.columns)` fonksiyonları çalıştırılmıştır.

Kullanılan Python Kodu:

```
print("--- BÖLÜM A: VERİ SETİNİ TANIMA ---")

# 1. Satır ve sütun sayısı
satir_sayisi, sutun_sayisi = df.shape
print(f"1. Veri setinde {satir_sayisi} satır ve {sutun_sayisi} sütun vardır. ")

# 2. Değişken isimleri
print(f"\n2. Değişkenlerin isimleri:\n{list(df.columns)} ")
```

Orijinal Kod Çıktısı:

```
--- BÖLÜM A: VERİ SETİNİ TANIMA ---
1. Veri setinde 327 satır ve 21 sütun vardır.

2. Değişkenlerin isimleri:
['Age', 'Gender', 'Marital status', 'Occupation / Daily Activities',
'Living situation', 'Family Heart problems History', 'Family Diabetes
History', 'Food habits', 'Physical activity', 'Sleep at night',
'Depression', 'Smoke or Tobacco', 'Alcohol', 'Feel stressed', 'Height
(cm)', 'Weight', 'BMI', 'Blood Pressure', 'Diabetes', 'Medicines',
'Heart patient']
```

Metodolojik Değerlendirme

Elde edilen analitik çıktılarına göre veri setinde 327 bireye (satır) ait kayıt ve bu bireylerin durumunu tasvir eden 21 adet öznitelik (sütun) yer almaktadır. Veri setinde tıp literatüründe en temel bağımsız risk faktörlerinden biri kabul edilen Age (Yaş) değişkeninin sürekli sayısal değerler yerine kategorik gruplar halinde toplanmış olması, modelin sürekli bir yaş doğrusu yerine belirli yaş eşiklerinin kardiyovasküler risk üzerindeki etkisini ölçeceğini göstermektedir. Analizin odak noktasını oluşturan ve bağımlı değişken işlevi gören hedef değişkenimiz ise iki sınıflı kategorik yapıdaki Heart patient sütunudur.

3.2. Değişken Tiplerinin Sınıflandırılması

Veri setindeki 21 öznitelik, matematiksel ve istatistiksel karakterlerine göre sayısal (nicel) ve kategorik (nitel) olarak iki ana sınıfa ayrıştırılmıştır.

Kullanılan Python Kodu:

```
# 3. Kategorik ve sayısal değişkenlerin ayrımı
sayisal_degiskenler =
df.select_dtypes(include=[np.number]).columns.tolist()
kategorik_degiskenler = df.select_dtypes(include=['object',
'category']).columns.tolist()
print(f"\n3. Sayısal Değişkenler: {sayisal_degiskenler}")
print(f"3. Kategorik Değişkenler: {kategorik_degiskenler} ")

# 4. Hedef değişken
hedef_degisken = 'Heart patient'
print(f"\n4. Hedef değişkenimiz: '{hedef_degisken}' sütunudur. [cite: 5, 8]")
```

Orijinal Kod Çıktısı:

```
3. Sayısal Değişkenler: ['Height (cm)', 'Weight', 'BMI']
3. Kategorik Değişkenler: ['Age', 'Gender', 'Marital status',
'Occupation / Daily Activities', 'Living situation', 'Family Heart
problems History', 'Family Diabetes History', 'Food habits', 'Physical
activity', 'Sleep at night', 'Depression', 'Smoke or Tobacco',
'Alcohol', 'Feel stressed', 'Blood Pressure', 'Diabetes', 'Medicines',
'Heart patient']

4. Hedef değişkenimiz: 'Heart patient' sütunudur. [cite: 5, 8]
```

Metodolojik Değerlendirme

Çıktılarda görüldüğü üzere antropometrik ölçümleri temsil eden Height (cm), Weight ve bu iki bileşenden türetilen BMI (Vücut Kitle İndeksi) olmak üzere veri setinde 3 adet sürekli sayısal değişken

bulunmaktadır. Buna karşın yaşam tarzı, klinik geçmiş ve demografik bilgileri içeren diğer 18 değişken ise kategorik yapıdadır.

Mesafe tabanlı veya gradyan inişli makine öğrenmesi algoritmaları metinsel ifadeleri doğrudan matematiksel denklemlere dahil edemezler. Bu doğrultuda, veri setindeki kategorik öznitelikler modelleme aşaması öncesinde sayısallaştırma işlemine (Label Encoding / One-Hot Encoding) tabi tutulmak üzere mimariye hazırlanmıştır.

3.3. Eksik Veri (Missing Value) ve Mükerrer Kayıt (Duplicate) Analizi

Veri setinde olası bir eksik veri durumunu ve analizin güvenilirliğini sarsacak mükerrer kayıt varlığını sorgulamak adına ilgili pandas fonksiyonları yürütülmüştür.

Kullanılan Python Kodu:

```
# 5. Eksik değer kontrolü
eksik_degerler = df.isnull().sum().sum()
print(f"\n5. Veri setindeki toplam eksik değer sayısı: {eksik_degerler}
")
if eksik_degerler > 0:
    print(df.isnull().sum()[df.isnull().sum() > 0])

# 6. Tekrar eden kayıt kontrolü
tekrar_edenler = df.duplicated().sum()
print(f"\n6. Veri setindeki tekrar eden (mükerrer) kayıt sayısı:
{tekrar_edenler} ")
```

Orijinal Kod Çıktısı:

```
5. Veri setindeki toplam eksik değer sayısı: 0
```

```
6. Veri setindeki tekrar eden (mükerrer) kayıt sayısı: 0
```

✈ *Metodolojik Değerlendirme*

- **Eksik Değer Yorumu:** Veri setinde hiç eksik değer bulunmadığı (0 eksik değer) doğrulanmıştır. Bu bulgu, veri interpolasyonu, ortalama/medyan ile doldurma (imputation) gibi ekstra ön işleme adımlarına gerek kalmadığını ve veri setinin analitik süreçler için yüksek bir bütünlüğe ve veri kalitesine sahip olduğunu göstermektedir.
- **Mükerrer Kayıt Yorumu:** Veri setinde 0 mükerrer kayıt olduğu tespit edilmiştir. Aynı bireye ait klinik kayıtların veri tabanına mükerrer olarak girilmesi, makine öğrenmesi modellerinin eğitim ve test aşamalarında aynı verilerle karşılaşarak ezber yapmasına (*overfitting*) neden olur.

Çıkan sıfır sonucu, 327 satırın her birinin birbirinden bağımsız, benzersiz ve özgün birer klinik vakayı/bireyi temsil ettiğini doğrulamaktadır.

4. Tanımlayıcı İstatistikler

Veri setinin merkezi eğilimlerini, dağılım genişliklerini, değişkenlerin kendi içindeki varyasyonlarını ve popülasyonun genel fizyolojik yapısını anlamak adına hem sayısal hem de kategorik değişkenler için tanımlayıcı istatistikler üretilmiştir. Keşifsel veri analizinin (EDA) bu evresi, ham verilerin sunduğu ham bilgiyi klinik birer göstergeye dönüştürmenin ve makine öğrenmesi modellerine giden yolda popülasyon karakteristiklerini anlamamanın en temel yoludur.

4.1. Sayısal Değişkenlerin Merkezi Eğilim ve Dağılım Analizi

Veri setinde sürekli sayısal (nicel) yapıda bulunan Height (cm), Weight ve bu iki bileşenden türetilen BMI (Vücut Kitle İndeksi) öznitelikleri için Python pandas kütüphanesinin df.describe().T fonksiyonu kullanılarak elde edilen orijinal kod bloku ve istatistiksel özet tablosu aşağıda sunulmuştur:

Kullanılan Python Kodu:

```
print("--- BÖLÜM B: TANIMLAYICI İSTATİSTİKLER ---")

# Sayısal değişkenler için özet istatistikler (Ortalama, medyan, std, min, max)
print("\n--- Sayısal Değişkenlerin Tanımlayıcı İstatistikleri --- [cite: 9]")
print(df.describe().T[['mean', '50%', 'std', 'min', 'max']].rename(columns={'50%': 'median'}))
```

Orijinal Kod Çıktısı:

```
--- BÖLÜM B: TANIMLAYICI İSTATİSTİKLER ---

--- Sayısal Değişkenlerin Tanımlayıcı İstatistikleri --- [cite: 9]
```

	mean	median	std	min	max
Height (cm)	163.072783	162.60	6.788715	137.20	182.90
Weight	67.179205	68.00	11.933481	42.00	103.00
BMI	25.237401	24.95	4.216494	16.51	42.46

✈ İstatistiksel Değerlendirme

- **Antropometrik Dağılım (Boy ve Kilo):** Katılımcıların boy ortalaması 163.07 cm (Medyan: 162.60 cm), kilo ortalaması ise 67.18 kg (Medyan: 68.00 kg) olarak saptanmıştır. Medyan ve ortalama değerlerinin birbirine oldukça yakın seyretmesi, bu iki parametrenin popülasyon genelinde simetriğe yakın (Normal dağılıma benzer) bir eğilim gösterdiğine işaret etmektedir.

Kilo değişkenindeki standart sapmanın 11.93 kg gibi nispeten yüksek bir değer olması, örneklem grubunda 42 kg ile 103 kg arasında değişen, fiziksel olarak oldukça heterojen bir kitle yapısının barındırdığını doğrulamaktadır.

- **Vücut Kitle İndeksi (BMI) ve Kardiyovasküler Risk Zemini:** Dünya Sağlık Örgütü (WHO) standartlarına göre 18.5 ile 24.9 kg/m² aralığı "Normal Kilolu" kabul edilirken, 25.0 ile 29.9 kg/m² aralığı "Fazla Kilolu" (Overweight) olarak sınıflandırılmaktadır. Analiz edilen 327 kişilik popülasyonun BMI ortalamasının **25.24 kg/m²** çıkması, kitlenin genel olarak **Fazla Kilolu** sınırının içerisinde girdiğini kanıtlamaktadır. Maksimum BMI değerinin 42.46 kg/m² seviyesine ulaşması, örneklemde ileri derece (3. derece / morbid) obez bireylerin de yer aldığını göstermektedir. Yüksek BMI, tıp literatüründe sistemik inflamasyonu tetikleyen, dislipidemiye yol açan, kalbin sol ventrikül iş yükünü artıran ve ateroskleroz patogenezi hızlandıran bağımsız bir risk faktörüdür. Bu veri, popülasyonun metabolik açıdan kalp hastalıklarına yatkın bir tabana sahip olduğunu nesnel olarak ortaya koymaktadır.

4.2. Kategorik Değişkenlerin Frekans ve Yüzde Dağılımları

Bu aşamada hedef değişken sınıf oranları, cinsiyet frekansları ve örneklem içindeki baskın mod değerlerini üreten Python kod bloku ve çıktısı aşağıda yer almaktadır:

Kullanılan Python Kodu:

```
# Kalp hastası sınıf dağılımı incelemesi
print("\n--- Heart Patient Sınıf Dağılımı --- [cite: 10]")
kalp_hastasi_sayisi = df['Heart patient'].value_counts()
kalp_hastasi_orani = df['Heart patient'].value_counts(normalize=True) * 100

print(f"Kalp Hastası Sayıları:\n{karp_hastasi_sayisi} [cite: 10]")
print(f"Kalp Hastası Oranları (%):\n{karp_hastasi_orani.round(2)} [cite: 11]")

# Cinsiyet dağılımı
print("\n--- Cinsiyet Dağılımı --- [cite: 11]")
print(df['Gender'].value_counts())

# En yaygın yaş grubu ve en yaygın kan basıncı kategorisi
print("\n--- En Yaygın Kategoriler ---")
if 'Age' in df.columns:
    print(f"En yaygın yaş grubu: {df['Age'].mode()[0]} [cite: 11]")
if 'Blood Pressure' in df.columns:
    print(f"En yaygın kan basıncı kategorisi: {df['Blood Pressure'].mode()[0]} [cite: 12]")
```

Orijinal Kod Çıktısı:

```
--- Heart Patient Sınıf Dağılımı ---
Kalp Hastası Sayıları:
Heart patient
No      219
Yes     108
Name: count, dtype: int64
Kalp Hastası Oranları (%):
Heart patient
No      66.97
Yes     33.03
Name: proportion, dtype: float64

--- Cinsiyet Dağılımı ---
Gender
Male      196
Female    131
Name: count, dtype: int64

--- En Yaygın Kategoriler ---
En yaygın yaş grubu: > 50
En yaygın kan basıncı kategorisi: Normal
```

İstatistiksel Değerlendirme

- **Heart Patient (Hedef Değişken) Sınıf Dengesi:** Veri setinde klinik olarak kalp hastası tanısı almamış sağlıklı kontrol grubu sayısı **219 (%66.97)** iken, doğrulanmış bir kalp hastalığı tanısına sahip birey sayısı **108 (%33.03)** olarak tespit edilmiştir. Toplum genelindeki epidemiyolojik prevalans oranları düşünüldüğünde, örneklemdeki pozitif sınıf (hasta) oranının %33.03 olması analitik modelleme açısından büyük bir avantajdır. Veri biliminde sıkça karşılaşılan ve azınlık sınıfın öğrenilememesine yol açan "aşırı sınıf dengesizliği" (severe class imbalance) kısıtı bu sayede aşılmıştır. Modellerimiz sentetik veri üretme yöntemlerine (SMOTE vb.) ihtiyaç duymadan, hem sağlıklı hem de hasta sınıfa ait örüntüleri dengeli bir biçimde öğrenebilecektir.
- **Cinsiyet Dağılımı ve Epidemiyolojik Önemi:** Örneklem 196'sı Erkek (%59.94), 131'i ise Kadın (%40.06) bireylerden oluşmaktadır. Klinik literatür, koroner arter hastalıklarının erkeklerde kadınlara kıyasla daha erken yaşlarda ve daha yüksek prevalansla ortaya çıktığını net bir biçimde ortaya koymaktadır. Kadınlarda menopoz öncesi dönemde salgılanan östrojen hormonu, lipid profilini optimize ederek ve endotel bazlı nitrik oksit sentezini artırarak kardiyoprotektif (kalp koruyucu) bir kalkan görevi üstlenir. Erkek yoğunluklu bu kitle yapısı, modelin cinsiyete bağlı patolojik eğilimleri daha güçlü yakalamasına olanak tanıyacaktır.
- **En Yaygın Yaş Grubu (Mod):** Popülasyonda en yüksek frekansa sahip yaş kategorisinin "> 50" (50 yaş üstü) olduğu saptanmıştır. Kronik kardiyovasküler deformasyonlar, arteriyel sertlik (ateroskleroz) ve birikimli hücrel stres zamanla biriken olgulardır. Dolayısıyla, örneklem olgun ve ileri yaş ağırlıklı bir kitleye odaklanmış olması, kalp sağlığı ve risk faktörleri arasındaki korelasyonları incelemek adına epidemiyolojik açıdan son derece isabetli bir popülasyon seçildiğini kanıtlamaktadır.

- **En Yaygın Kan Basıncı (Blood Pressure) Durumu:** Katılımcılar arasında en sık rastlanan kan basıncı modu "**Normal**" olarak belirlenmiştir. Genel kitlede normal tansiyon yapısının baskın olması ilk bakışta olumlu bir sağlık göstergesi gibi görünse de, bu değişkenin kalp hastası olanlar ile olmayanlar arasındaki çapraz dağılımı (Bölüm D), hipertansiyonun gerçek ve ölümcül riskini daha net görünür kılacaktır.

5. Görselleştirmeler

Keşifsel veri analizinin en güçlü araçlarından biri olan veri görselleştirme; değişkenlerin dağılım morfolojilerini, veri setindeki yığılma noktalarını, sınıflar arası geçişkenliği ve hedef değişkenle olan doğrusal olmayan ilişkileri görünür kılmaktadır. Bu çalışma kapsamında, ödev yönergesinde talep edilen 6 zorunlu grafik yapısı Python matplotlib ve seaborn kütüphaneleri kullanılarak tek bir subplot matrisinde (3x2) bir araya getirilmiştir. Grafikler oluşturulurken okunabilirliği artırmak adına eksen isimleri, kategori etiketleri, lejantlar (legend) ve akademik başlıklar eksiksiz bir şekilde entegre edilmiştir.

5.1. Görselleştirme Kod Bloğu

Aşağıdaki kod bloku, popülasyon karakteristiklerini ve kardiyovasküler risk faktörlerinin hedef değişken olan Heart patient ile olan ilişkilerini görselleştirmek amacıyla çalıştırılmıştır:

```
# 6'lı subplot düzeni oluşturma
fig, axes = plt.subplots(3, 2, figsize=(16, 18))
fig.suptitle('Veri Seti Görselleştirme ve Kalp Hastalığı İlişkileri',
fontsize=18, fontweight='bold')

# Grafi 1: Heart patient dağılımı (Bar Chart)
sns.countplot(ax=axes[0, 0], x='Heart patient', data=df, palette='Set2')
axes[0, 0].set_title('Heart Patient Sınıf Dağılımı', fontsize=12,
fontweight='bold')
axes[0, 0].set_xlabel('Kalp Hastası mı?')
axes[0, 0].set_ylabel('Kişi Sayısı')

# Grafik 2: Yaş grubuna göre kalp hastalığı dağılımı
sns.countplot(ax=axes[0, 1], x='Age', hue='Heart patient', data=df,
palette='viridis')
axes[0, 1].set_title('Yaş Grubuna Göre Kalp Hastalığı Dağılımı',
fontsize=12, fontweight='bold')
axes[0, 1].set_xlabel('Yaş Grubu')
axes[0, 1].set_ylabel('Kişi Sayısı')
axes[0, 1].tick_params(axis='x', rotation=45)

# Grafik 3: Cinsiyete göre kalp hastalığı dağılımı
```

```
sns.countplot(ax=axes[1, 0], x='Gender', hue='Heart patient', data=df,
palette='pastel')
axes[1, 0].set_title('Cinsiyete Göre Kalp Hastalığı Dağılımı',
fontsize=12, fontweight='bold')
axes[1, 0].set_xlabel('Cinsiyet')
axes[1, 0].set_ylabel('Kişi Sayısı')

# Grafik 4: BMI dağılımı (Boxplot)
sns.boxplot(ax=axes[1, 1], x='Heart patient', y='BMI', data=df,
palette='coolwarm')
axes[1, 1].set_title('Kalp Hastalığı Durumuna Göre BMI Dağılımı',
fontsize=12, fontweight='bold')
axes[1, 1].set_xlabel('Kalp Hastası mı?')
axes[1, 1].set_ylabel('BMI Değeri')







# Grafik 5: Blood Pressure ve Heart patient ilişkisi
sns.countplot(ax=axes[2, 0], x='Blood Pressure', hue='Heart patient',
data=df, palette='magma')
axes[2, 0].set_title('Kan Basıncı Kategorilerine Göre Kalp Hastalığı',
fontsize=12, fontweight='bold')
axes[2, 0].set_xlabel('Kan Basıncı (Blood Pressure)')
axes[2, 0].set_ylabel('Kişi Sayısı')
axes[2, 0].tick_params(axis='x', rotation=45)

# Grafik 6: Physical activity ve Heart patient ilişkisi
sns.countplot(ax=axes[2, 1], x='Physical activity', hue='Heart patient',
data=df, palette='cubehelix')
axes[2, 1].set_title('Fiziksel Aktiviteye Göre Kalp Hastalığı',
fontsize=12, fontweight='bold')
axes[2, 1].set_xlabel('Fiziksel Aktivite Seviyesi')
axes[2, 1].set_ylabel('Kişi Sayısı')

plt.tight_layout(rect=[0, 0, 1, 0.96])
plt.show()
```

Kod Çıktısı

Veri Seti Görselleştirme ve Kalp Hastalığı İlişkileri



5.2. Grafiklerin Yorumları

Grafik 1: Heart Patient Sınıf Dağılımı Analysis

- **Klinik ve İstatistiksel Bulgular:** Popülasyonun genel sınıf dengesini gösteren bu çubuk grafikte, sağlıklı kontrol grubunun (No) 219 kişiyle majör sınıfı, kalp hastası olan grubun (Yes) ise 108 kişiyle minör sınıfı oluşturduğu görsel olarak teyit edilmiştir. Görseldeki dikey sütun farkı, veri biliminde modellerin azınlık sınıfı tamamen görmezden gelerek sadece baskın sınıfa göre tahmin yapması kısıtını (over-representation) tetikleyecek boyutta değildir. Bu dengeli dağılım, modellerin hem patolojik örüntüleri hem de sağlıklı fizyolojik durumları eşit hassasiyetle öğrenebilmesi adına ideal bir zemin sunmaktadır.

Grafik 2: Yaş Grubuna Göre Kalp Hastalığı Dağılımı Analysis

- **Klinik ve İstatistiksel Bulgular:** Bu grafik, kardiyovasküler yaşlanmanın en net kanıtlarından birini sunmaktadır. 35 yaş altındaki grupta (< 35) kalp hastalığı frekansı son derece düşük seviyede (yaklaşık 10 kişi), 35-50 yaş arasında bu oran kademeli olarak yükselmektedir. Asıl radikal kırılma ise " > 50 " (**50 yaş üstü**) grubunda gerçekleşmektedir. Bu grupta kalp hastası olan bireylerin sayısı (~67 vaka), sağlıklı olan bireylerin sayısını (~64 vaka) geride bırakmıştır. Klinik literatürde yaşla birlikte arter duvarlarında kollajen birikimi, elastikiyet kaybı (arteriyel sertlik) ve birikimli endotel deformasyonu beklendiği için, verinin bu yaş segmentinde "safha değiştirmesi" epidemiyolojik açıdan son derece anlamlıdır.

Grafik 3: Cinsiyete Göre Kalp Hastalığı Dağılımı Analysis

- **Klinik ve İstatistiksel Bulgular:** Dağılım incelendiğinde, örneklemdaki erkek popülasyonunun absolute (mutlak) olarak kadınlara kıyasla daha fazla kalp hastası barındırdığı görülmektedir (59 Erkek vaka / 49 Kadın vaka). Örneklem oranları bazında incelendiğinde ise, her iki cinsiyette de kalp hastası olanlar ile olmayanlar arasındaki dikey oran makul bir paralellik göstermektedir. Erkeklerdeki yüksek vaka hacmi, tıp dünyasında erkeklerin bütün kullanımı gibi mikro-davranışsal risk faktörlerine olan yüksek maruziyeti ve androjenik hormonların vasküler direnç üzerindeki mekanik etkileriyle doğrudan örtüşmektedir.

Grafik 4: Kalp Hastalığı Durumuna Göre BMI Dağılımı Analysis

- **Klinik ve İstatistiksel Bulgular:** İki sınıfın Vücut Kitle İndeksi (BMI) dağılımları Kutu Grafiği (Boxplot) üzerinden kıyaslandığında, medyan çizgilerinin 25 kg/m^2 (Fazla Kilolu sınırı) civarında birbiriyle örtüştüğü görülmektedir. Ancak dikkat çeken temel fark, varyans genişliği

ve aykırı değerlerdir (outliers). Kalp hastası olan popülasyonda (Yes), BMI üst çeyreklik çizgisi ve 40 kg/m² değerinin üzerine çıkan morbid obezite varyasyonları çok daha belirgindir. Bu durum, yüksek BMI değerinin tek başına doğrusal bir etki yaratmasa da, diğer metabolik risk faktörleriyle birleştiğinde (örneğin diyabet ve hipertansiyon) kardiyak patolojileri besleyen gürültülü bir tetikleyici olduğunu doğrulamaktadır.

Grafik 5: Kan Basıncı Kategorilerine Göre Kalp Hastalığı Analysis

- **Klinik ve İsninistikselsel Bulgular:** Şüphesiz grafik matrisindeki en dramatik patolojik kırılma bu grafikte izlenmektedir. Normal, Pre-hypertension ve Hypotension gruplarında sağlıklı bireylerin oranı ezici bir çoğunluğa sahipken; "**Hypertension**" (**Hipertansiyon**) sütununa gelindiğinde senaryo tamamen tersine dönmektedir. Hipertansiyon kategorisinde kalp hastası olanların sayısı (~50), sağlıklı olanları (~36) açık ara geçmiştir. Klinik olarak kronik yüksek kan basıncı; damar içi hidrostatik basıncı artırarak endotel yırtılmalarına, sol ventrikül hipertrofisine ve kalbin kronik olarak aşırı yük altında çalışmasına neden olur. Bu grafik, hipertansiyonun koroner arter hastalıklarının "sessiz katili" olduğu gerçeğini matematiksel olarak doğrulamaktadır.

Grafik 6: Physical Activity ve Heart Patient İlişkisi Analysis

- **Klinik ve İstatistiksel Bulgular:** Yaşam tarzının kardiyoprotektif (kalp koruyucu) etkisini ölçen bu grafikte muazzam bir detay göze çarpmaktadır: Haftada 5 gün veya daha fazla spor yaptığını beyan eden grupta (5 or more days per week) **kalp hastası sayısı tam olarak sıfırdır (0 vaka)**. Egzersiz sıklığı azaldıkça, özellikle sedanter yaşamı temsil eden "haftada 2 günden az" (Less than 2 days per week) segmentinde kalp hastası yoğunluğunun (~61 vaka) dramatik şekilde tırmandığı izlenmektedir. Düzenli fiziksel aktivite; miyokard perfüzyonunu optimize eder, HDL (iyi kolesterol) seviyelerini yükseltir, nitrik oksit senteziyle damarları genişletir ve istirahat nabzını düşürür. Grafikteki spor yapan kitlede hastalık oranının sıfırlanması, egzersizin klinik gücünü tek başına ispatlamaktadır.

6. Risk Faktörü Analizi (Çapraz Tablolar)

Bu bölümde, veri setinde yer alan ve kardiyovasküler risk havuzunu oluşturduğu düşünülen **8 ana bağımsız değişken**, hedef değişkenimiz olan Heart patient ile çapraz tablolara (Cross-tabulation) tabi tutulmuştur. İlgili analizlerde satır bazlı yüzdesel normalizasyon (normalize='index') kullanılmıştır; bu sayede her bir risk faktörünün kendi alt kategorileri içerisindeki kalp hastası olma oranları (Yes) ve sağlıklı kalma oranları (No) net bir şekilde ayrıştırılmıştır.

Aşağıda, yürütülen Python kod bloğu, orijinal konsol çıktıları ve her bir risk faktörü için kılavuzda talep edilen dört kritik sorunun (İlişkili mi? Belirgin fark var mı? Grafik destekliyor mu? Sağlık bilgisine uygun mu?) yanıtlandığı klinik/verisel değerlendirmeler yer almaktadır.

6.1. Risk Faktörleri Analizi Kod Bloğu ve Çıktısı

```
print("--- BÖLÜM D: RİSK FAKTÖRLERİ ANALİZİ (ÇAPRAZ TABLOLAR) --- ")

# İncelenecek 8 ana risk faktörü listesi
risk_faktorleri = ['Age', 'Gender', 'Blood Pressure', 'Diabetes',
'Physical activity', 'Smoke or Tobacco', 'Alcohol', 'Feel stressed']

for faktor in risk_faktorleri:
    if faktor in df.columns:
        print(f"\n--- {faktor} ve Heart patient ilişkisi (Satır Yüzdesi) ---")

        ct = pd.crosstab(df[faktor], df['Heart patient'],
normalize='index') * 100
        print(ct.round(2))
```

Kod Çıktısı:

```
--- BÖLÜM D: RİSK FAKTÖRLERİ ANALİZİ (ÇAPRAZ TABLOLAR) ---

--- Age ve Heart patient ilişkisi (Satır Yüzdesi) ---
Heart patient      No      Yes
Age
35-50              71.56  28.44
< 35              88.51  11.49
> 50              48.85  51.15

--- Gender ve Heart patient ilişkisi (Satır Yüzdesi) ---
Heart patient      No      Yes
Gender
Female            62.6   37.4
Male             69.9   30.1

--- Blood Pressure ve Heart patient ilişkisi (Satır Yüzdesi) ---
Heart patient      No      Yes
Blood Pressure
Hypertension      41.86  58.14
Hypotension       88.24  11.76
Normal            80.33  19.67
Pre-hypertension  68.63  31.37

--- Diabetes ve Heart patient ilişkisi (Satır Yüzdesi) ---
Heart patient      No      Yes
Diabetes
Diabetes          58.82  41.18
Normal            78.10  21.90
Prediabetes       59.09  40.91

--- Physical activity ve Heart patient ilişkisi (Satır Yüzdesi) ---
Heart patient      No      Yes
Physical activity
```

2-4 days per week	58.11	41.89
5 or more days per week	100.00	0.00
Less than 2 days per week	63.69	36.31
Rarely / Never	77.46	22.54

--- Smoke or Tobacco ve Heart patient ilişkisi (Satır Yüzdesi) ---

Heart patient	No	Yes
Smoke or Tobacco		
Never	65.79	34.21
Occasionally	62.96	37.04
Regularly	72.34	27.66

--- Alcohol ve Heart patient ilişkisi (Satır Yüzdesi) ---

Heart patient	No	Yes
Alcohol		
High/Frequent	60.00	40.00
Moderate	68.29	31.71
Never	67.60	32.40
Occasionally	61.29	38.71

--- Feel stressed ve Heart patient ilişkisi (Satır Yüzdesi) ---

Heart patient	No	Yes
Feel stressed		
High	70.97	29.03
Low	60.87	39.13
Moderate	68.82	31.18
Never	72.22	27.78

6.2. Bulguların Değerlendirmesi

✦ 1. Yaş (Age) Faktörü

- **Analiz ve Farklar:** Yaş değişkeni kalp hastalığı ile **doğrudan ve güçlü bir ilişki** göstermektedir. Gruplar arasında radikal bir makas mevcuttur: 35 yaş altındaki bireylerde kalp hastası olma oranı yalnızca %11.49 iken, bu oran 35-50 yaş arasında %28.44'e, **50 yaşın üzerinde ise %51.15'e** fırlamaktadır. 50 yaş üstü grupta kalp hastası olma ihtimali adeta bir yazı-tura dengesine (yarı yarıya) evrilmiştir.
- **Grafik ve Literatür Uyumu:** Bu bulgu, Bölüm C'deki Şekil 2 grafiği ile tamamen desteklenmektedir. Yaşlandıkça damar endotel yapısının bozulması, koroner arter kalsifikasyonunun birikmesi ve arteriyel kompliyansın azalması tıp literatürünün temel taşlarındandır; dolayısıyla sonuçlar **klินิก açıdan son derece mantıklıdır**.

✦ 2. Cinsiyet (Gender) Faktörü

- **Analiz ve Farklar:** Cinsiyet bazında satır yüzdelere bakıldığında, kadınların %37.40'ının, erkeklerin ise %30.10'unun kalp hastası olduğu görülmektedir. Bölüm B'deki mutlak vaka sayılarında erkek hastalar (59 vaka) kadınlardan (49 vaka) fazla olsa da, kadın örneklem popülasyonu daha küçük (131 kişi) olduğu için grup içi hastalık oranı kadınlarda daha yüksek çıkmıştır.

- **Grafik ve Literatür Uyumu:** Şekil 3 grafiğindeki sütun yükseklikleri bu yüzdesel dağılımı görselleştirmektedir. Normal şartlarda klinikte erkeklerin koroner arter hastalıklarına yakalanma riski menopoza öncesi kadınlara kıyasla daha yüksek kabul edilir. Ancak bu veri setindeki kadın hastaların yaş kırılımı (örneğin menopoza sonrası >50 yaş grubunda yoğunlaşmış olmaları) bu oranı invertine (tersine dönmesine) sebep olmuş olabilir. Küçük örneklem kısıtı göz önünde bulundurulmalıdır.

✦ 3. Kan Basıncı (Blood Pressure) Faktörü

- **Analiz ve Farklar:** Kan basıncı, hedef değişkenle **en keskin ve dramatik farkı oluşturan** faktördür. Düşük tansiyonda (Hypotension) hastalık oranı %11.76, normal tansiyonda %19.67, sınırda tansiyonda (Pre-hypertension) %31.37 iken; **Hipertansiyon (Hypertension) hastalarında bu oran %58.14'e** ulaşmaktadır.
- **Grafik ve Literatür Uyumu:** Şekil 5 grafiğindeki mor (sağlıklı) ve pembe (hasta) sütunların hipertansiyon kategorisinde yön değiştirmesi bu farkı gözler önüne sermektedir. Kronik yüksek kan basıncının damar duvarında yarattığı mekanik stres, ateroskleroz patogenezi tetikler ve sol ventrikül iş yükünü artırır. Bulgular **kardiyoloji literatürüyle mükemmel bir uyum** içerisindedir.

✦ 4. Diyabet (Diabetes) Faktörü

- **Analiz ve Farklar:** Glikoz metabolizması durumu kalp sağlığı ile yakından ilişkilidir. Normal glikoz seviyelerine sahip bireylerde kalp hastalığı oranı %21.90 iken, bu oran **Prediyabet (gizli şeker) hastalarında %40.91'e, Diyabet hastalarında ise %41.18'e** yükselmektedir.
- **Grafik ve Literatür Uyumu:** Diyabetik ve prediyabetik durum, normal gruba kıyasla riski tam iki katına çıkarmaktadır. İnsülin direnci ve kronik hiperglisemi, makrovasküler endotel hasarına yol açarak koroner arter hastalığı sürecini hızlandırdığı için elde edilen bulgular **tıbbi açıdan tamamen tutarlıdır**.

✦ 5. Fiziksel Aktivite (Physical Activity) Faktörü

- **Analiz ve Farklar:** Fiziksel aktivite koruyucu bir faktör olarak belirgin bir fark ortaya koymaktadır. En dikkat çekici bulgu, haftada 5 gün ve daha fazla spor yapan bireylerde (5 or more days per week) **kalp hastalığı oranının %0.00 (tamamen sıfır)** olmasıdır. Buna karşın, sedanter yaşam sürenlerde risk %36.31 ile %41.89 arasında değişmektedir.
- **Grafik ve Literatür Uyumu:** Şekil 6 grafiğinde spor yapan grupta hasta sütununun hiç bulunmaması bu analitiği destekler. Haftada 2-4 gün spor yapanların, hiç yapmayanlara göre

kağıt üzerinde daha yüksek riskli görünmesi ise bir **ters nedensellik (reverse causality)** göstergesi olabilir; yani halihazırda kalp rahatsızlığı teşhisi konmuş bireyler hekim tavsiyesiyle haftada 2-4 gün hafif egzersiz yapmaya başlamış olabilirler. Bu durum veri bilimi açısından mantıklıdır.

✦ 6. Sigara ve Tütün Kullanımı (Smoke or Tobacco) Faktörü

- **Analiz ve Farklar:** Veri setinde hiç sigara içmeyenlerin (Never) %34.21'i, ara sıra içenlerin (Occasionally) %37.04'ü kalp hastasıyken, düzenli içenlerin (Regularly) %27.66'sı kalp hastası çıkmıştır.
- **Grafik ve Literatür Uyumu:** Bu durum tıp literatürünün tam aksine bir "**paradoks**" sunmaktadır. Normal şartlarda sigaranın koroner vazokonstriksiyonu ve pıhtılaşmayı artırarak kalp riskini tırmandırması beklenir. Düzenli içenlerdeki bu düşük oran, veri setinin hacminin küçük olmasından (~327 satır) veya veri setindeki genç popülasyonun sigara içme oranının yüksek ancak henüz kalp hastalığı geliştirecek yaşa gelmemiş olmasından kaynaklanan bir **seçilim / hayatta kalma (survivor) yanlılığı** olabilir.

✦ 7. Alkol Tüketimi (Alcohol) Faktörü

- **Analiz ve Farklar:** Alkol tüketimi ile kalp hastalığı arasında hafif bir korelasyon izlenmiştir. Hiç alkol almayanlar (%32.40) ile orta düzeyde alanlar (%31.71) benzer risk oranlarına sahipken, alkol tüketimi **yüksek/sık olan grupta risk %40.00'a**, ara sıra tüketenlerde ise %38.71'e çıkmaktadır.
- **Grafik ve Literatür Uyumu:** Aşırı alkol tüketiminin toksik etkileri, miyokardiyal fonksiyon bozuklukları ve aritmi riskini artırdığı için yüksek tüketim grubundaki %40'lık oran **sağlık bilgisiyle örtüşmektedir**.

✦ 8. Stres Hissi (Feel Stressed) Faktörü

- **Analiz ve Farklar:** Stres seviyesi "Düşük" olan grupta kalp hastalığı oranı %39.13 iken, "Yüksek" olan grupta %29.03, "Moderate" (Orta) grupta %31.18 ve "Hiç" stres yaşamayanlarda %27.78 olarak hesaplanmıştır.
- **Grafik ve Literatür Uyumu:** Kronik stresin kortizol ve sempatik aktivasyon üzerinden kalp hastalığını tetiklemesi beklendiği için, düşük streslilerin yüksek streslilere göre daha hasta çıkması literatürle çelişmektedir. Bu anomali, **hastaların öz-beyanına (self-reported)** dayalı anket verilerinin sübjektifliğinden kaynaklanmaktadır. Kalp hastalığı teşhisi alıp tedaviye

başlayan ve yaşam tarzını sakinleştiren bireyler stres seviyelerini artık "Düşük" olarak beyan etmiş olabilirler. Bu durum, veri setinin sınırlılıkları bölümünde detaylıca ele alınacaktır.

7. Makine Öğrenmesi Modeli

Veri analizi sürecinin bu evresinde, veri ön işleme aşamasında sayısallaştırılan öznitelikler kullanılarak tahmine dayalı modelleme hattı (*predictive modeling pipeline*) inşa edilmiştir. Projenin bu bölümünde, bir bireyin demografik, klinik ve yaşam tarzı verilerine dayanarak kalp hastası (Heart patient) olup olmadığını öngörebilen gözetimli öğrenme (*supervised learning*) sınıflandırma modelleri kurulmuştur.

7.1. Modelleme Metodolojisi ve Veri Bölme Stratejisi

Algoritmik eğitime geçilmeden önce, veri setindeki kategorik metin öznitelikleri LabelEncoder bileşeni kullanılarak tamsayı tabanlı matris formuna getirilmiştir. Modelin gelecekte karşılaşılabileceği yeni ve görülmemiş verilere karşı genelleme yeteneğini nesnel bir biçimde ölçebilmek adına veri seti **%80 Eğitim (Train)** ve **%20 Test** olacak şekilde ikiye ayrılmıştır.

Sınıf dağılımının eğitim ve test kümelerinde homojen kalmasını sağlamak ve rastgele bölünmeden kaynaklanabilecek temsil adaletsizliklerini engellemek amacıyla stratify=y parametresi devreye alınmıştır. Bölünme sonucunda elde edilen veri hacimleri şu şekildedir:

- **Eğitim Seti Boyutu:** 261 Satır, 20 Bağımsız Değişken
- **Test Seti Boyutu:** 66 Satır, 20 Bağımsız Değişken

Proje yönergesinde yer alan algoritmik çeşitlilik kriterini karşılamak üzere, doğrusal tabanlı bir sınıflandırıcı olan **Lojistik Regresyon (Logistic Regression)** ile ağaç tabanlı ve parametrik olmayan bir toplu öğrenme (*ensemble learning*) algoritması olan **Rastgele Orman (Random Forest)** modelleri seçilerek paralel olarak eğitilmiştir.

7.2. Modelleme Kod Bloğu ve Çıktılar

Aşağıdaki kod yapısı, modellerin eğitim süreçlerini, test kümesi üzerindeki tahmin adımlarını, kafa karışıklığı matrislerinin (*confusion matrix*) üretimini ve öznitelik önem derecelerinin hesaplanmasını sağlamaktadır:

```
print("--- BÖLÜM E: MAKİNE ÖĞRENMEŞİ MODELLERİ --- [cite: 18]")

# 1. Verinin kopyasını oluşturma ve Kategorik Değişkenlerin
Sayısallaştırılması
df_model = df.copy()
```

```

le = LabelEncoder()

for col in df_model.select_dtypes(include=['object',
'category']).columns:
    df_model[col] = le.fit_transform(df_model[col].astype(str))

# Bağımsız değişkenler (X) ve Hedef Değişken (y) ayrımı
X = df_model.drop(columns=['Heart patient'])
y = df_model['Heart patient']

# 2. Tren-Test Ayrımı (%80 Train, %20 Test)
X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.20, random_state=42, stratify=y)
print(f"Eğitim Seti Boyutu: {X_train.shape}, Test Seti Boyutu:
{X_test.shape} [cite: 20]")

# 3. Model 1: Logistic Regression
lr_model = LogisticRegression(max_iter=1000, random_state=42)
lr_model.fit(X_train, y_train)
lr_preds = lr_model.predict(X_test)

# Model 2: Random Forest
rf_model = RandomForestClassifier(random_state=42)
rf_model.fit(X_train, y_train)
rf_preds = rf_model.predict(X_test)

# 4. Performans Karşılaştırma Fonksiyonu
def model_performans_raporu(y_true, y_pred, model_adi):
    print(f"\n===== {model_adi} Performansı
=====")
    print(f"Accuracy: {accuracy_score(y_true, y_pred):.4f} [cite: 21]")
    print(f"Precision: {precision_score(y_true, y_pred):.4f} [cite:
21]")
    print(f"Recall: {recall_score(y_true, y_pred):.4f} [cite: 21]")
    print(f"F1-Score: {f1_score(y_true, y_pred):.4f} [cite: 21]")
    print(f"\nConfusion Matrix: [cite: 21]")
    print(confusion_matrix(y_true, y_pred))

# Performans sonuçlarını yazdırma
model_performans_raporu(y_test, lr_preds, "Logistic Regression [cite:
19]")
model_performans_raporu(y_test, rf_preds, "Random Forest [cite: 19]")

# 5. Öznitelik Önem Düzeyleri (Random Forest için En Önemli Değişkenler)
print(f"\n===== Random Forest Değişken Önem Dereceleri
=====")
importances = rf_model.feature_importances_
indices = np.argsort(importances)[::-1]

```

```
for f in range(X.shape[1]):
    print(f"{f + 1}. Değişken: {X.columns[indices[f]]}
    ({importances[indices[f]]:.4f}) [cite: 24]")
```

Çıktı Kümesi:

```
--- BÖLÜM E: MAKİNE ÖĞRENME Sİ MODELLERİ --- [cite: 18]
Eğitim Seti Boyutu: (261, 20), Test Seti Boyutu: (66, 20) [cite: 20]

===== Logistic Regression [cite: 19] Performansı =====
=====
Accuracy:  0.7727 [cite: 21]
Precision: 0.8182 [cite: 21]
Recall:    0.4091 [cite: 21]
F1-Score:  0.5455 [cite: 21]

Confusion Matrix: [cite: 21]
[[42  2]
 [13  9]]

===== Random Forest [cite: 19] Performansı =====
Accuracy:  0.7424 [cite: 21]
Precision: 0.7273 [cite: 21]
Recall:    0.3636 [cite: 21]
F1-Score:  0.4848 [cite: 21]

Confusion Matrix: [cite: 21]
[[41  3]
 [14  8]]

===== Random Forest Değişken Önem Dereceleri =====
1. Değişken: BMI (0.1128) [cite: 24]
2. Değişken: Height (cm) (0.0972) [cite: 24]
3. Değişken: Weight (0.0967) [cite: 24]
4. Değişken: Blood Pressure (0.0917) [cite: 24]
5. Değişken: Age (0.0709) [cite: 24]
6. Değişken: Marital status (0.0566) [cite: 24]
7. Değişken: Occupation / Daily Activities (0.0491) [cite: 24]
8. Değişken: Feel stressed (0.0457) [cite: 24]
9. Değişken: Medicines (0.0430) [cite: 24]
10. Değişken: Physical activity (0.0425) [cite: 24]
11. Değişken: Smoke or Tobacco (0.0420) [cite: 24]
12. Değişken: Alcohol (0.0374) [cite: 24]
13. Değişken: Diabetes (0.0374) [cite: 24]
14. Değişken: Depression (0.0370) [cite: 24]
15. Değişken: Family Heart problems History (0.0303) [cite: 24]
16. Değişken: Family Diabetes History (0.0274) [cite: 24]
17. Değişken: Gender (0.0259) [cite: 24]
18. Değişken: Sleep at night (0.0257) [cite: 24]
19. Değişken: Food habits (0.0230) [cite: 24]
20. Değişken: Living situation (0.0080) [cite: 24]
```

7.3. Performans Metriklerinin Matematiksel Gösterimi ve Karşılaştırma Matrisi

Modelleri değerlendirirken kullanılan temel veri bilimi metrikleri, aşağıdaki formal matematiksel denklemler üzerinden hesaplanmaktadır:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F - 1 \text{ Score} = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Eđitilen iki modelin test kümesinden elde ettiđi tüm performans çıktıları, raporlama standartlarına uygun şekilde aşağıdaki özet tablosunda karşılaştırılmıştır:

Deđerlendirme Kriteri	Lojistik Regresyon (Logistic Regression)	Rastgele Orman (Random Forest)
Test Accuracy (Dođruluk)	0.7727	0.7424
Test Precision (Kesinlik)	0.8182	0.7273
Test Recall (Duyarlılık)	0.4091	0.3636
Test F1-Score	0.5455	0.4848
Dođru Sađlıklı Tahmini (TN)	42	41
Hatalı Hasta Tahmini (FP)	2	3
Gözden Kaçan Hasta (FN)	13	14
Dođru Hasta Teşhisi (TP)	9	8

7.3.1. Performans Tablosunun Kısa Özeti ve Ön Deđerlendirme

Elde edilen performans matrisi, sabit bir karar eşiđinde (threshold = 0.5) iki modelin kararlılıđını ve klinik hata paylarını somut bir şekilde ortaya koymaktadır:

- **Genel Başarıda Lojistik Regresyon:** Lojistik Regresyon; Doğruluk (0.7727), Kesinlik (0.8182) ve F1-Skor (0.5455) metriklerinin tamamında Rastgele Orman modelini geride bırakarak bu veri setinde daha tutarlı bir duruş sergilemiştir. Modelin yanlış alarm (False Positive) sayısı yalnızca 2'dir.
- **Kritik Teşhis Zafiyeti (Düşük Recall):** Sağlık senaryolarında en hayati metrik olan Duyarlılık (Recall), her iki modelde de sınıfta kalmıştır. Lojistik Regresyon test setindeki 22 gerçek hastanın 13'ünü, Rastgele Orman ise 14'ünü sağlıklı zannederek (**False Negative**) gözden kaçırmıştır. Modellerin hasta yakalama oranları (%40.91 ve %36.36) klinik kullanım için oldukça yetersizdir.
- **Köprü Yorum:** Sabit matristeki bu sonuçlar Lojistik Regresyon'u öne çıkarsa da, modellerin başarısını tek bir kesim noktasına bağlı kalmadan, tüm olası olasılık eşikleri genelinde değerlendirmek gerekmektedir. Modellerin gerçek sınıf ayırım gücünü ve saklı potansiyellerini tam olarak görebilmek adına bir sonraki adımda üretilen **ROC Eğrileri ve AUC Skorları** devreye girmektedir.

7.4. İsteğe Bağlı Analiz: ROC Eğrisi ve AUC Hesaplama Protokolü

Sınıflandırma modellerinin başarısını sadece tek bir kesim noktasına (sabit olasılık eşiği) bağlı kalmaksızın, tüm olası karar eşikleri genelinde değerlendirmek amacıyla **ROC (Receiver Operating Characteristic)** eğrisi analizi gerçekleştirilmiştir. Aşağıdaki kod yapısı, her iki modelin test kümesine ait tahmin olasılıklarını işleyerek Yanlış Pozitif Oranı (FPR) ve Doğru Pozitif Oranı (TPR) değerlerini grafiksel matrise dökmektedir:

Kullanılan Python Kodu:

```
from sklearn.metrics import roc_curve, auc


# Logistic Regression için ROC ve AUC hesaplama
lr_probs = lr_model.predict_proba(X_test)[: , 1]
lr_fpr, lr_tpr, _ = roc_curve(y_test, lr_probs)
lr_auc = auc(lr_fpr, lr_tpr)

# Random Forest için ROC ve AUC hesaplama
rf_probs = rf_model.predict_proba(X_test)[: , 1]
rf_fpr, rf_tpr, _ = roc_curve(y_test, rf_probs)
rf_auc = auc(rf_fpr, rf_tpr)

# ROC eğrilerini çizdirme
plt.figure(figsize=(10, 8))
plt.plot(lr_fpr, lr_tpr, color='blue', lw=2, label=f'Logistic Regression (AUC = {lr_auc:.2f})')
```

```
plt.plot(rf_fpr, rf_tpr, color='red', lw=2, label=f'Random Forest (AUC = {rf_auc:.2f})')
plt.plot([0, 1], [0, 1], color='gray', lw=2, linestyle='--', label='Rastgele Sınıflandırıcı (AUC = 0.50)')
plt.xlabel('False Positive Rate (Yanlış Pozitif Oranı)')
plt.ylabel('True Positive Rate (Doğru Pozitif Oranı)')
plt.title('ROC Eğrileri ve AUC Skorları')
plt.legend(loc='lower right')
plt.grid(True)
plt.show()
```

Kod Çıktısı:



7.4.1. ROC ve AUC Sonuçlarının Yorumlanması

- **Grafik Başlığı:** Şekil 7: Modellerin ROC Eğrileri ve Sınıflandırma Ayrım Güçlerinin Karşılaştırılması
- **Eksen İsimleri:** X Eksen: False Highlight Rate (Yanlış Pozitif Oranı) | Y Eksen: True Positive Rate (Doğru Pozitif Oranı / Recall)

- **Klinik ve Analitik Analiz:** Elde edilen ROC grafiđi incelendiđinde, her iki modelin de kőşegeni temsil eden ve tamamen şansa dayalı tahmin yürüten "Rastgele Sınıflandırıcı" ($AUC = 0.50$) referans doğrusunun belirgin şekilde üzerinde konumlandığı görölmektedir. Bu durum, modellerimizin şans eseri karar vermediğini, öznelilikler içindeki patolojik örüntüleri anlamlı derecede kavradığını kanıtlar.
- **AUC Skor Paradoksu:** Sabit matrikste Lojistik Regresyon öne çıkmış olsa da, genel ayırt edici gücü simgeleyen AUC (Eđri Altında Kalan Alan) skorlarında **Rastgele Orman ($AUC = 0.80$)**, Lojistik Regresyon modelini ($AUC = 0.79$) geride bırakmıştır. Bu durum, Rastgele Orman modelinin aslında sınıfları birbirinden ayırma potansiyelinin daha yüksek olduğunu, ancak varsayılan 0.5 olasılık eşiğinde tıkanıđını gösterir. Klinik bir uygulamada, karar mekanizmasının olasılık eşiğı (örneğin risk hassasiyetini artırmak için eşik deęerini 0.35 seviyesine çekmek) optimize edilirse, Rastgele Orman modelinin çok daha yüksek bir Recall (Duyarlılık) seviyesine ulaşarak gerçek hayatta daha fazla hastayı kurtarabileceğı veri bilimi açısından öngörülebilir.

8. Bulguların Yorumlanması

Bu bölümde, makine öğrenmesi modellerinin test kümesi üzerinde ürettiğı performans metrikleri, karmaşıklık matrisleri (*confusion matrix*) ve ROC-AUC çıktıları, tıp literatürü ile veri bilimi metodolojisi ekseninde çok boyutlu bir analize tabi tutulmuştur.

8.1. Algoritmik Sınıflandırma Başarılarının Karşılaştırmalı Analizi

Modellerin test verisi üzerindeki genel kararlılıkları incelendiğinde, doğrusal tabanlı bir sınıflandırıcı olan **Lojistik Regresyon (Logistic Regression)** modelinin, ağaç tabanlı bir toplu öğrenme (*ensemble*) algoritması olan **Rastgele Orman (Random Forest)** modeline kıyasla daha başarılı sonuçlar ürettiğı saptanmıştır.

Lojistik Regresyon; genel doğruluk (Accuracy: 0.7727), pozitif sınıf tahmin temizliğı (Precision: 0.8182) ve metrik dengesi (F1-Score: 0.5455) kriterlerinin tamamında Rastgele Orman modelini (Accuracy: 0.7424, Precision: 0.7273, F1-Score: 0.4848) geride bırakmıştır. Bunun temel teknik gerekçesi, 327 satırlık görece küçük örneklem hacimlerinde, çok parametrelili ve karmaşık dallanmalara sahip ağaç yapılarının aşırı öğrenmeye (*overfitting*) veya varyans dalgalanmalarına kapılma riskinin, doğrusal sınır çizen Lojistik Regresyon'a göre daha yüksek olmasıdır.

Ancak, tüm olası karar eşiklerinin ortalamasını alan genel ayırt edici güç kriterine (AUC skoru) bakıldığında, Rastgele Orman modelinin ($AUC = 0.80$) Lojistik Regresyon'u ($AUC = 0.79$) kıl payı geride bıraktığı görölmüştür. Bu durum, Rastgele Orman modelinin sınıfları birbirinden ayırma

potansiyelinin yüksek olduğunu, fakat varsayılan 0.5 olasılık eşliğinde iyi kalibre edilemediğini kanıtlamaktadır.

8.2. Sınıf Dengesizliği ve Metriklerin Sınırları: Accuracy Paradoksu

Veri bilimi ve makine öğrenmesi süreçlerinde **Doğruluk (Accuracy) tek başına kesinlikle yeterli bir başarı metriği değildir**. Bunun nedeni, gerçek dünya sağlık verilerinde sıklıkla karşılaşılan sınıf dengesizliği (*class imbalance*) durumudur.

Test kümemiz incelendiğinde, 66 bireyin 44'ünün sağlıklı kontrol grubuna (No), 22'sinin ise kalp hastası grubuna (Yes) ait olduğu görülmektedir. Eğer geliştirilen algoritma veri setindeki hiçbir örüntüyü öğrenmeyip, sisteme giren herkese körü körüne "Sağlıklı" (No) deseydi bile, matematiksel olarak **%66.66** gibi yüksek bir Accuracy skoru elde edecekti. Modellerimizin elde ettiği %77.27 ve %74.24'lik Accuracy değerleri, ilk bakışta başarılı görünse de, arka plandaki sınıf bazlı zafiyetleri maskeleyen yanıltıcı birer göstergedir. Bu sebeple, özellikle klinik senaryolarda modellerin başarıları değerlendirilirken Accuracy yerine Precision, Recall ve F1-skor gibi doğrudan hedef sınıfa odaklanan metriklerin incelenmesi zorunludur.

8.3. Klinik Senaryolarda Duyarlılığın (Recall) Hayati Önemi ve Model Performansı

- Sağlık bilişimi, medikal yapay zeka ve epidemiyolojik tarama sistemlerinde **Recall (Duyarlılık / Hassasiyet)** en kritik, hata payı lüksü olmayan metriktir. Recall, evrende gerçekten hasta olan bireylerin yüzde kaçının model tarafından başarıyla yakalanabildiğini ölçer. Klinik bir senaryoda, sağlıklı bir bireye yanlışlıkla "Kalp Hastası" teşhisi koymanın (Yanlış Pozitif - False Positive) maliyeti sadece kişiye ek bir check-up veya laboratuvar testi yaptırmaktır. Ancak, gerçek bir kalp hastasını gözden kaçırıp (Yanlış Negatif - False Negative) ona "Sağlıklıdır, eve gidebilirsiniz" demenin maliyeti doğrudan ölümcül krizler, enfarktüs ve telafi edilemez can kayıplarıdır. Bu yüzden medikal tarama araçlarında Recall değerinin \$0.90\$ ve üzerinde olması hedeflenir.
- Kafa karışıklığı matrisi (*confusion matrix*) ve metrik tabloları incelendiğinde, **geliştirilen modellerin kalp hastası olan bireyleri başarılı bir şekilde yakalayamadığı net bir biçimde görülmektedir**. En başarılı model olan Lojistik Regresyonun dahi Recall skoru **0.4091** seviyesinde kalmıştır. Matris verilerine göre test setindeki 22 gerçek kalp hastasından yalnızca 9'una doğru teşhis konulabilmiş, **13 hasta ise model tarafından sağlıklı zannedilerek ıskalanmıştır (False Negative)**. Benzer şekilde Rastgele Orman modeli de 22 hastanın 14'ünü gözden kaçırarak %36.36'lık bir Recall skoru üretmiştir. Sonuç olarak, iki model de hasta popülasyonu yakalama görevinde klinik olarak tamamen başarısızdır ve bu halleriyle can güvenliği riski barındırmaktadırlar.

8.4. Öznitelik Önem Dereceleri (Feature Importance) ve Patolojik Korelasyonlar

Rastgele Orman modelinin kararları üretirken dallanma adımlarında en çok faydalandığı bilgi kazancı (*information gain*) kriterlerine göre öznitelik önem dereceleri incelendiğinde, tıp literatürüyle tam uyumlu, hiyerarşik bir risk haritası karşımıza çıkmaktadır:

1. **Antropometrik Katman (BMI: 0.1128, Height: 0.0972, Weight: 0.0967):** Algoritmanın kararlarında en yüksek varyans açıklayıcı güce sahip olan birincil blok %11.28 ile **BMI** ve fiziksel ölçümler olmuştur. Tanımlayıcı istatistiklerde popülasyon genelinin "Fazla Kilolu" sınırında çıkması bulgusuyla birleştiğinde, vücut kitle indeksindeki değişimlerin modelin hastaları ayırt etmesindeki en birincil bilgi kaynağı olduğu doğrulanmıştır.
2. **Klinik ve Yaş Katmanı (Blood Pressure: 0.0917, Age: 0.0709):** Modelin en çok ağırlık verdiği sonraki iki parametre **Kan Basıncı** ve **Yaş** olmuştur. Bölüm D'deki çapraz tablolarda hipertansiyon hastalarının %58.14'ünün, 50 yaş üstünün ise %51.15'inin kalp hastası çıktığı gerçeği, algoritma tarafından da matematiksel olarak keşfedilmiş ve bu iki değişkene yüksek bilgi ağırlığı (toplamda ~%16.26) verilmiştir.
3. **Destekleyici Yaşam Tarzı Katmanı:** Stres hissi (0.0457), kullanılan ilaçlar (0.0430), fiziksel aktivite (0.0425) ve tütün kullanımı (0.0420) gibi parametreler ise %4 civarında seyreden birbirine yakın ağırlıklarla, modelin karar mekanizmasını arka planda besleyen tamamlayıcı faktörler olarak kayda geçmiştir.

9. Sınırlılıklar

Veri bilimi ve epidemiyolojik araştırmalarda, geliştirilen modellerin ve elde edilen istatistiksel çıkarımların meşruiyeti, çalışmanın kısıtlarının ve sınırlılıklarının akademik bir şeffaflıkla ortaya konulmasına bağlıdır. Bu çalışma kapsamında inşa edilen makine öğrenmesi modellerinin ve veri analizlerinin sahip olduğu yapısal ve operasyonel kısıtlar metodolojik gerekçeleriyle sınıflandırılmıştır:

9.1. Örneklem Boyutu ve Genelleme Kısıtı

Analiz edilen veri seti yalnızca 327 bireye ait kayıt barındırmaktadır. Büyük veri analitiği ve tahmine dayalı yapay zeka standartları açısından bu hacim oldukça küçük ve kısıtlı bir örnekleme temsil etmektedir. Veri setinin küçük olması, makine öğrenmesi modellerinin popülasyondaki nadir fizyolojik örüntüleri derinlemesine öğrenmesini engellemektedir. Bu durum, modellerin test setinde yüksek varyans sergilemesine yol açarak, elde edilen başarı skorlarının genel popülasyona ve farklı etnik veya sosyo-demografik kitlelere genellenmesini klinik açıdan kısıtlamaktadır.

9.2. Öz-Beyan (Self-Reported) Veri Yanlılığı

Veri setinde yer alan bağımlı hedef değişken ile tütün kullanımı, alkol, stres hissi ve depresyon gibi kritik yaşam tarzı öznitelikleri, nesnel hekim muayeneleri veya klinik laboratuvar tetkikleri yerine tamamen katılımcıların anket sorularına verdikleri kendi beyanlarına dayanmaktadır. İnsanların toplumsal kabul görme arzusuyla sigara veya alkol tüketimlerini az beyan etme eğilimleri veya stres durumlarını tamamen sübjektif şekilde yorumlamaları, veri setine doğrudan sistematik gürültü (*systematic noise*) ve hatırlama yanlılığı (*recall bias*) olarak yansımaktadır. Bu durum, sigara ve stres değişkenlerinde karşılaşılan tıp literatürüne aykırı bazı paradoksal sonuçların birincil sebebidir.

9.3. Algoritmik Teşhis ve Güvenlik Sınırları

Modellerin klinik ortamlarda kullanılmasının önündeki en büyük algoritmik engel, Duyarlılık (Recall) skorlarının %36.36 ve %40.91 gibi kabul edilemez derecede düşük seviyelerde kalmasıdır. Kafa karışıklığı matrisinde net olarak görüldüğü üzere, test kümesindeki 22 gerçek kalp hastasından 13 veya 14 tanesi model tarafından sağlıklı zannedilerek gözden kaçırılmıştır. Gerçek hayatta bu denli yüksek iskalama oranına sahip bir algoritmanın klinik karar destek sistemlerine entegre edilmesi, hekimlerde ve hastalarda sahte bir güven hissi yaratarak gerçek teşhis ve tedavi süreçlerinin gecikmesine sebebiyet verecektir.

10. Sonuç

Bu final projesi çalışmasında, kardiyovasküler risk faktörlerini barındıran anket ve klinik gösterge veri tabanı üzerinde uçtan uca bir analiz hattı başarıyla yürütülmüştür. Çalışmadan elde edilen nihai akademik ve klinik çıkarımlar aşağıda sunulmuştur:

10.1. Kalp Hastalığı ile En Çok İlişkili Faktörler ve Literatür Uyumu

Analiz sonuçlarına göre veri setinde kalp hastalığı ile en güçlü ve belirgin ilişkiyi gösteren faktörler Kan Basıncı (Blood Pressure), Yaş (Age), Diyabet Durumu (Diabetes) ve Fiziksel Aktivite (Physical activity) olarak öne çıkmaktadır. Yaş, BMI, diyabet ve hipertansiyon değişkenleri tıp literatüründeki beklentilerle kusursuz bir uyum göstermiştir. 50 yaş üstü bireylerde hastalık oranı %51.15'e ulaşırken, Hipertansiyon segmentinde bu oran %58.14'e fırlayarak yüksek hidrolik basıncın koroner arterler üzerindeki yıkıcı etkisini doğrulamıştır. Diyabet ve prediyabet ise hastalık riskini tam iki katına çıkarmıştır. Benzer şekilde, haftada 5 gün ve daha fazla spor yapan kitlede kalp hastalığı oranının tamamen sıfır çıkması, fiziksel aktivitenin kardiyoprotektif gücünü net olarak kanıtlamıştır. Sigara kullanımı ve stres hissi değişkenleri ise, veri setinin küçük olması ve öz-beyana dayalı anket yapısından kaynaklanan gürültüler sebebiyle tıp literatürünün aksine paradoksal yüzdelere sahip çıkmıştır.

10.2. Veri Setinin Güçlü Yönleri

Veri setinin en büyük gücü, bir bireyin kardiyovasküler risk profilini sadece boy, kilo gibi antropometrik veya tansiyon gibi klinik verilerle sınırlı tutmayıp; uyku düzeni, beslenme, stres, depresyon, medeni durum ve aile geçmişi gibi psikososyal ve mikrodavranışsal yaşam tarzı öznitelikleriyle çok boyutlu olarak harmanlamış olmasıdır. Bu zengin çeşitlilik, geniş tabanlı bir risk analizi yapılmasına olanak tanımıştır. Ayrıca veri setinde sıfır eksik veri ve sıfır mükerrer kayıt bulunması teknik açıdan veri bütünlüğünü artırmaktadır.

10.3. Daha İleri Analizler İçin Gerekli Ek Veriler

Geliştirilen yapay zeka modellerinin ayırt edici gücünü ve özellikle hasta yakalama hassasiyetini (Recall) dünya standartlarına ulaştırabilmek için veri setine şu nesnel klinik parametrelerin eklenmesi elzemdir:

1. **Biyokimyasal Laboratuvar Bulguları:** LDL, HDL Kolesterol seviyeleri, Trigliserid, Açlık Kan Şekeri (HbA1c) ve inflamasyon göstergeleri.
2. **Objektif Kardiyak Ölçümler:** Katılımcılara ait EKG (Elektrokardiyografi) dalga verileri, Ejeksiyon Fraksiyonu (EF) oranları ve koroner kalsiyum skorları.
3. **Genetik ve Kantitatif Yaşam Tarzı Verileri:** Ailede birinci derece akrabaların anjiyo geçmişi verileri ile sübjektif stres anketleri yerine günlük tüketilen tütün miktarı gibi sürekli sayısal veriler.

10.4. Gerçek Hayatta Klinik Karar Yeterliliği

Bu veri seti ve geliştirilen modeller ile gerçek hayatta kesinlikle klinik karar verilemez, tanı konulamaz ve tedavi protokolü oluşturulamaz. Tıp ve kardiyoloji pratikleri, hata payının doğrudan insan hayatıyla ölçüldüğü disiplinlerdir. Modellerimizin gerçek kalp hastalarının %60'a yakınına ıskalayan mevcut performansı, örneklem hacminin sadece 327 kişiyle sınırlı olması ve verilerin sübjektif anket beyanlarına dayanması, bu çalışmayı klinik bir tanı aracı olmaktan uzaklaştırmaktadır. Bu çalışma, mevcut haliyle ancak eğitim odaklı bir akademik simülasyon ve epidemiyolojik bir ön inceleme raporu olarak kabul edilebilir.

Kaynakça

American Psychological Association. (2020). *Publication manual of the American Psychological Association* (7th ed.). <https://doi.org/10.1037/0000165-000>

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2nd ed.). Springer Science & Business Media. <https://doi.org/10.1007/978-0-387-84858-7>

Heart Disease Risk Factors and Patient Health Survey Dataset. (2026). *Heart_Dataset_Cleaned* [Veri seti]. Büyük Veri Analizi Final Projesi kapsamında sağlanan veri tabanı.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: with applications in R and Python* (2nd ed.). Springer. <https://doi.org/10.1007/978-1-0716-1418-1>

McKinney, W. (2010). Data structures for statistical computing in python. *Proceedings of the 9th Python in Science Conference*, 51–56. <https://doi.org/10.25080/Majora-92bf15d0-00a>

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12(85), 2825–2830.

World Health Organization. (2021). *Cardiovascular diseases (CVDs) Fact Sheets*. World Health Organization. [https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-\(cvds\)](https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds))