

BÜYÜK VERİ ANALİZİ FİNAL PROJESİ: KISA SONUÇ ÖZETİ

1. Veri Yapısı ve Popülasyon Karakteristikleri

- Veri Hacmi ve Kalitesi:** Analiz edilen veri tabanı 327 satır ve 21 öznitelikten oluşmakta olup, yapılan kontrollerde sıfır eksik değer ve sıfır mükerrer kayıt ile yüksek bir analitik bütünlüğe sahip olduğu doğrulanmıştır.
- Sınıf Dağılımı:** Popülasyonun %66.97'si (219 kişi) sağlıklı kontrol grubunu oluştururken, %33.03'ü (108 kişi) klinik olarak kalp hastası tanısına sahiptir. Sınıflar arası dağılım modelleme için idealdir.
- Genel Karakteristikler:** Örneklemde 196 Erkek ve 131 Kadın yer almaktadır. En yaygın yaş grubu 50 yaş üstü (> 50), en sık rastlanan kan basıncı kategorisi ise Normal olarak saptanmıştır.
- Metabolik Zemin:** Popülasyonun Vücut Kitle İndeksi (BMI) ortalaması 25.24 kg/m^2 olup, kitlenin genel olarak "Fazla Kilolu" (Overweight) sınırında konumlandığı nesnel olarak kanıtlanmıştır.

2. Öne Çıkan Klinik ve Yaşam Tarzı Bulguları

- Yaş Faktörü:** 35 yaş altındaki bireylerde kalp hastalığı oranı %11.49 iken, 50 yaşın üzerinde bu oran %51.15'e tırmanarak yaşlanmaya bağlı risk artışını doğrulamıştır.
- Kan Basıncı Tehlikesi:** Normal tansiyona sahip bireylerde hastalık oranı %19.67 iken, Hipertansiyon (Hypertension) grubunda bu oran %58.14'e yükselerek en keskin patolojik kırılmayı oluşturmuştur.
- Diyabet Etkisi:** Sağlıklı bireylerde kalp rahatsızlığı prevalansı %21.90 iken; Diyabet hastalarında %41.18, Prediyabetiklerde ise %40.91 ile risk oranı tam iki katına çıkmaktadır.
- Egzersiz Koruyucu Gücü:** Haftada 5 gün veya daha fazla spor yapan bireyler arasında kalp hastalığı oranı %0.00 (tamamen sıfır) olarak saptanmıştır. Fiziksel aktivite azaldıkça hastalık yoğunluğu %41.89 seviyesine tırmanmaktadır.
- Veri Anomalileri:** Sigara kullanımı ve kronik stres hissi gibi bazı anket değişkenlerinde, küçük örneklem boyutu ve hastaların sübjektif yorumlamalarından (*öz-beyan / self-reported*) kaynaklanan gürültüler nedeniyle literatürle çelişen paradoksal yüzdelere gözlemlenmiştir.

3. Makine Öğrenmesi Modelleri ve Performans Sonuçları

- Lojistik Regresyon Performansı:** Sabit 0.5 olasılık eşiğinde Doğruluk (Accuracy) %77.27, Kesinlik (Precision) %81.82, Duyarlılık (Recall) %40.91 ve F1-Skor 0.5455 olarak üretilmiştir. Genel başarıda ve yanlış alarm üretmeme kulvarında en kararlı algoritmadır.
- Rastgele Orman Performansı:** Sabit 0.5 olasılık eşiğinde Doğruluk %74.24, Kesinlik %72.73, Duyarlılık %36.36 ve F1-Skor 0.4848 olarak kayda geçmiştir.
- Genel Ayrım Gücü (AUC):** Tüm olası kesim noktalarını değerlendiren AUC skorunda Rastgele Orman (0.80), Lojistik Regresyon modelini (0.79) kıl payı geride bırakarak, doğru bir eşik optimizasyonu yapıldığında daha yüksek bir potansiyel taşıdığını göstermiştir.
- Değişken Önem Dereceleri:** Algoritmanın karar mekanizmasında en çok ağırlık verdiği ilk beş öznitelik sırasıyla; BMI (0.1128), Boy (0.0972), Kilo (0.0967), Kan Basıncı (0.0917) ve Yaş (0.0709) olarak sıralanmıştır.

4. Yapısal Sınırlılıklar ve Nihai Klinik Hüküm

- Teşhis Hassasiyeti (Recall) Zafiyeti:** En başarılı model olan Lojistik Regresyon dahi test setindeki 22 gerçek kalp hastasından yalnızca 9'unu doğru teşhis edebilmiş, 13 hastayı gözden kaçırmıştır (%40.91 Recall). Gerçek hastaları yüksek oranda iskalayan bir modelin klinik güvenliği bulunmamaktadır.
- Klinik Yeterlilik Kararı:** Küçük örneklem boyutu (327 kişi), objektif biyokimyasal laboratuvar verilerinin (lipid profili, EKG dalgaları vb.) eksikliği ve bazı anket girdilerinin öz-beyana (*self-reported*) dayanması en büyük kısıtlardır.
- Nihai Hüküm:** Bu veri seti ve modeller ile gerçek hayatta kesinlikle klinik karar verilemez ve medikal tanı konulamaz. Bu çalışma, mevcut haliyle ancak yüksek nitelikli bir akademik simülasyon ve epidemiyolojik bir ön inceleme niteliğindedir.